

# Методы определения достаточного размера выборки в параметрических моделях

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

# Достаточный размер выборки в нейронных сетях

## Цель

Разработать метод численной оценки **достаточного размера** обучающей выборки для параметрических моделей.

## Проблема

Существующие эмпирические законы масштабирования не имеют общего теоретического обоснования. Классические статистические методы неприменимы ввиду большого числа параметров модели.

## Метод решения

Предлагается связать достаточный размер выборки с геометрией **поверхности эмпирической функции потерь**. Вводится критерий сходимости, фиксирующий изменения от добавления новых обучающих данных в **подпространстве наибольшей кривизны**.

# Построение критерия сходимости поверхности потерь

## Данные и модель

Выборка  $\mathfrak{D}_k = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^k$  из распределения  $p(\mathbf{x}, \mathbf{y})$ , параметрическая модель  $f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$ ,  $\mathbf{w} \in \mathbb{R}^N$ , функция потерь на одном объекте  $\ell_i(\mathbf{w}) = \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$ . Эмпирическая функция потерь и ее минимум:

$$\mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \ell_i(\mathbf{w}), \quad \mathbf{w}_k^* = \arg \min_{\mathbf{w}} \mathcal{L}_k(\mathbf{w}).$$

## Стабилизация ландшафта

При добавлении объекта ( $k \rightarrow k+1$ ) изменение поверхности в окрестности минимума измеряется критерием  $\Delta(k+1) \geq 0$ .

## Достаточный размер выборки

При заданном уровне  $\varepsilon > 0$ :  $k^*(\varepsilon) = \min\{k : \Delta(k') \leq \varepsilon \quad \forall k' \geq k\}$ .

## Задача


Построить критерий  $\Delta$ , согласованный с геометрией поверхности функции потерь, получить оценку скорости убывания  $\Delta(k) = \mathcal{O}(k^{-\alpha})$  и выразить через нее достаточный размер выборки  $k^*(\varepsilon)$ .

# Унифицированный критерий $p$ -сходимости

Критерий  $p$ -сходимости ландшафта функции потерь при добавлении одного объекта в выборку  $\mathfrak{D}_k$ :

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$

где  $q : \mathbb{R}^N \rightarrow \mathbb{R}_+$  задает предпочтение по выбору точек в пространстве параметров.




- 1) Без ограничения общности  $\int q(\mathbf{w}) d\mathbf{w} = 1$ , т. е.  $q(\mathbf{w})$  — плотность распределения;
- 2) Существующие подходы — частные выборы пары  $(p, q)$ :  
одноточечный (Дирак) и среднеквадратичный (гаусс в  $\mathbb{R}^N$ );
- 3) Локальный интерес  $\Rightarrow q(\mathbf{w})$  с массой возле минимума.

# Абсолютный одноточечный критерий сходимости

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где  $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$  — точка из окрестности радиуса  $R > 0$  минимума  $\mathbf{w}_k^*$ , т. е.  $p = 1$  и  $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$ . Теоретические свойства критерия определяются вектором градиента  $\mathbf{g}_k(\mathbf{w}) = \nabla_{\mathbf{w}} \mathcal{L}_k(\mathbf{w})$  функции потерь и ее матрицей Гессе  $\mathbf{H}_k(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_k(\mathbf{w})$ .



## Теорема (Киселев, 2024)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация  $\mathcal{L}_k(\mathbf{w})$ , причем  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$  и для всех  $i = 1, \dots, k+1$  верно  $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$ , тогда


$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

# Среднеквадратичный критерий сходимости

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[ (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

т. е.  $p = 2$ , для теоретического анализа удобно выбрать  $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$ , а на практике базово вычисляется методом Монте—Карло через  $\mathbf{w}_s \sim q(\mathbf{w})$ :

$$\hat{\Delta}_2(k+1) = \frac{1}{S} \sum_{s=1}^S (\mathcal{L}_{k+1}(\mathbf{w}_s) - \mathcal{L}_k(\mathbf{w}_s))^2.$$



## Теорема (Киселев, 2025)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация  $\mathcal{L}_k(\mathbf{w})$ , причем  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$  и для всех  $i = 1, \dots, k+1$  верно  $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$ , тогда

$$\Delta_2(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (N^2 + 2N) M_{\mathbf{H}}}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

## Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны

$\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$ ,  $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$ ,  
 $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D]$ ,  $\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$ , тогда  
 критерий с  $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$ :


$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[ (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

На практике базово вычисляется методом Монте—Карло через  $\mathbf{w}_s = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_s$ , где  $\mathbf{z}_s \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$  и  $D \ll N$ .

Теорема (Киселев, 2026)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация  $\mathcal{L}_k(\mathbf{w})$ ,  
 причем  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$  и для всех  $i = 1, \dots, k+1$  верно  
 $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$ , тогда

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (D^2 + 2D) M_{\mathbf{H}}}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



# Численные методы оценки $\Delta_2^{(D)}$

## Цель

Численно оценить  $\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[ (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right]$  при  $\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}$ ,  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$ . В координатах  $\mathbf{z}$  разность аппроксимируется квадратично:  $\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) \approx a_k + \mathbf{c}_k^\top \mathbf{z} + \frac{1}{2} \mathbf{z}^\top \mathbf{B}_k \mathbf{z}$ ,  
 $a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*)$ ,  $\mathbf{c}_k = \mathbf{U}_D^\top \mathbf{g}^{(k+1)}$ ,  $\mathbf{B}_k = \mathbf{U}_D^\top (\mathbf{H}^{(k+1)} - \mathbf{H}^{(k)}) \mathbf{U}_D$ .

## Методы оценки

- 1) **Монте—Карло:** прямое усреднение по  $S$  сэмплам  $\mathcal{O}(S(ND + C_{\text{fwd}}))$

$$\hat{\Delta}_2(k+1) = \frac{1}{S} \sum_{s=1}^S (\mathcal{L}_{k+1}(\mathbf{w}_s) - \mathcal{L}_k(\mathbf{w}_s))^2$$

- 2) **Квадратичная Монте—Карло:** подстановка аппроксимации  $\mathcal{O}(SD^2)$

$$\hat{\Delta}_{2,\text{quad}}^{(D)}(k+1) = \frac{1}{S} \sum_{s=1}^S \left( a_k + \mathbf{c}_k^\top \mathbf{z}_s + \frac{1}{2} \mathbf{z}_s^\top \mathbf{B}_k \mathbf{z}_s \right)^2$$




- 3) **Замкнутая форма (GM):** аналитическое усреднение по  $\mathbf{z}_s$   $\mathcal{O}(D^2)$

$$\hat{\Delta}_{2,\text{GM}}^{(D)}(k+1) = a_k^2 + a_k \sigma^2 \text{Tr}(\mathbf{B}_k) + \sigma^2 \|\mathbf{c}_k\|_2^2 + \frac{\sigma^4}{4} (2 \text{Tr}(\mathbf{B}_k^2) + \text{Tr}(\mathbf{B}_k)^2)$$



# Вычислительный эксперимент 1: подпространство наибольшей кривизны и анизотропия ландшафта


**Постановка:** классификация MNIST полносвязной сетью, обучаемой методом Adam. Ведущие собственные векторы матрицы Гессе  $\mathbf{H}^{(k)}(\mathbf{w}_k^*)$  вычисляются итерационным спектральным методом на произведениях матрицы Гессе на вектор.



Собственные значения убывают  $\Rightarrow$  **локализация кривизны** в подпространстве небольшой размерности. Двумерные сечения функции потерь вдоль ведущих собственных векторов сильно **анизотропны** в сравнении со случайными направлениями.

## Вычислительный эксперимент 2: скорость убывания критериев и подгонка степенного закона

Зависимость критериев  $\Delta_1(k)$ ,  $\Delta_2(k)$  и  $\Delta_2^{(D)}(k)$  от размера обучающей выборки  $k$  оценивается методом Монте—Карло на сетке  $k \in \{100, 150, \dots, 10^4\}$ . К каждой зависимости подгоняется степенной закон  $\Delta(k) \sim k^{-\alpha}$ .



| Критерий            | $\alpha$ | $R^2$ | Теория |
|---------------------|----------|-------|--------|
| $\Delta_1$          | 2,33     | 0,63  | 1      |
| $\Delta_2$          | 1,94     | 1,00  | 2      |
| $\Delta_2^{(D=5)}$  | 1,80     | 0,96  | 2      |
| $\Delta_2^{(D=10)}$ | 1,83     | 0,99  | 2      |
| $\Delta_2^{(D=20)}$ | 1,84     | 0,99  | 2      |

Численные показатели  $\alpha$  для  $\Delta_2$  и  $\Delta_2^{(D)}$  согласуются с теоретическими.

## Выносятся на защиту

- 1) Предложен унифицированный критерий  $p$ -сходимости  $\Delta_p$  с функцией предпочтения в пространстве параметров. Критерий охватывает одноточечную и интегральные постановки стабилизации ландшафта функции потерь.
- 2) Введен среднеквадратичный критерий  $\Delta_2^{(D)}$  в подпространстве ведущих собственных векторов Гессе. Доказаны теоремы об экстремальности этого подпространства и разработаны численные методы оценки критерия.
- 3) Эмпирически исследована сходимость критерия  $\Delta_2^{(D)}$  при увеличении размера выборки. На основе оценок скорости убывания критерия предложен метод определения достаточного объема обучающих данных.

### Публикации в рецензируемых научных журналах (БАК, Scopus)

- 1) **Kiselev N., Meshkov V., Grabovoy A.** Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2025.
- 2) **Meshkov V., Kiselev N., Grabovoy A.** ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *Ivannikov Ispras Open Conference (ISPRAS) – IEEE*, 2024.
- 3) **Kiselev N., Grabovoy A.** Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.