

# Методы определения достаточного размера выборки в параметрических моделях

Киселев Никита Сергеевич

Научный руководитель: к.ф.-м.н. Грабовой А. В.

Кафедра интеллектуальных систем ФПМИ МФТИ

Специализация: Интеллектуальный анализ данных

Направление: 09.04.01 Информатика и вычислительная техника

Москва — 2026

# Законы масштабирования и достаточный размер выборки

Исследуется связь между архитектурой параметрической модели, локальной геометрией оптимизационной поверхности и объемом данных для устойчивого обучения.

## Проблема

Эмпирические законы масштабирования для современных моделей хорошо наблюдаются на практике, однако не имеют общего теоретического объяснения. При этом множество оптимальных параметров зависит от конечной обучающей выборки.

## Требуется

Построить теоретическую схему, связывающую архитектуру модели, локальную кривизну поверхности функции потерь и достаточный размер обучающей выборки.

## Метод решения

Предлагается анализировать **стабилизацию ландшафта функции потерь** при увеличении объема выборки. Для линейных моделей используются апостериорные распределения параметров, для нейросетей — локальная геометрия поверхности и спектральные свойства матрицы Гессе.

# Разложение Гаусса—Ньютона матрицы Гессе

## Эмпирическая функция потерь

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m, \quad \mathbf{x} \in \mathbb{R}^n, \quad \mathbf{y} \in \mathbb{R}^K$$

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$$

## Матрица Гессе

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}$$

## Обозначения на одном объекте

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}) \in \mathbb{R}^K, \quad \mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N},$$

$$\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, \mathbf{y}) \in \mathbb{R}^{K \times K}$$

## Разложение Гаусса—Ньютона

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$$


$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$$

$$\mathbf{R}(\mathbf{w}) = \sum_{k=1}^K \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_k} \nabla_{\mathbf{w}}^2 z_k$$

## Ключевая идея

В окрестности минимума  $\|\mathbf{G}(\mathbf{w})\|_2 \approx \|\mathbf{H}(\mathbf{w})\|_2$ , поэтому далее локальная кривизна анализируется через **гаусс—ньютоновскую компоненту**  $\|\mathbf{G}(\mathbf{w})\|_2$ .

# Блочная факторизация гаусс—ньютоновская компоненты $\mathbf{G}(\mathbf{w})$



## Лемма (Киселев, 2026)

Для нейронной сети  $f_{\mathbf{w}}$  с архитектурой  $\mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)})$ ,  $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$ , где операторы  $T_{\mathbf{w}^{(p)}}^{(p)}$  линейны по входу, каждый блок  $\mathbf{G}^{(p,q)}(\mathbf{w})$  выражается через параметрические якобианы слоев  $\mathbf{P}^{(p)}(\mathbf{w}) = \partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$  и матрицы распространения возмущения  $\mathbf{S}^{(p)}(\mathbf{w}) = \partial \mathbf{z} / \partial \mathbf{z}^{(p)}$  по формуле  $\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)} \mathbf{P}^{(q)}$ .

# Спектральные оценки и вычислительный эксперимент 1

## Теорема (Киселев, 2024)

Пусть  $f_{\mathbf{w}}$  является  $L$ -слойной

**полносвязной** нейронной сетью,

$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$ ,  $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$ , и для всех

$p = 1, \dots, L$  верно  $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$ ,

$\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$ , тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}$$

## Теорема (Мешков, Киселев, 2024)

Пусть  $f_{\mathbf{w}}$  является  $L$ -слойной **сверточной**

нейронной сетью,  $K_{\max} = \max_p(C_{\text{out}})$ ,


$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$ ,  $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}$ , и для всех

$p = 1, \dots, L$  верно  $\|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}$ ,

$\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$ , тогда

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}$$

- 1) 10-классовая классификация MNIST;
- 2) Архитектура CNN, варьируются  $L$  и  $h$ ;
- 3) Спектральная норма численно оценивается методом степенных итераций.




# Критерий сходимости поверхности функции потерь

Критерий  $p$ -сходимости ландшафта функции потерь при добавлении одного объекта в выборку  $\mathfrak{D}_k$ :

$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$

где функция  $q : \mathbb{R}^N \rightarrow \mathbb{R}_+$  задает предпочтение по выбору точек в пространстве параметров модели для оценки сходимости.




- 1) Без ограничения общности,  $\int q(\mathbf{w}) d\mathbf{w} = 1$ , т.е.  $q(\mathbf{w})$  суть плотность распределения;
- 2) Нас интересует локальная геометрия в окрестности минимума  $\rightarrow$  определяем  $q(\mathbf{w})$  с основной массой возле минимума.

# Абсолютный одноточечный критерий сходимости

Абсолютный одноточечный критерий сходимости:

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где  $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$  — точка из окрестности радиуса  $R > 0$  минимума  $\mathbf{w}_k^*$ , т.е.  $p = 1$  и  $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$ .



## Теорема (Киселев, 2024)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация,  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$  и для всех  $i = 1, \dots, k+1$  верно  $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$ , тогда

$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

# Среднеквадратичный критерий сходимости

Среднеквадратичный критерий сходимости:

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[ (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$


т.е.  $p = 2$ , для теоретического анализа удобно выбрать  $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$ , а на практике вычисляется методом Монте—Карло через  $\mathbf{w}_s \sim q(\mathbf{w})$ :

$$\hat{\Delta}_2(k+1) = \frac{1}{S} \sum_{s=1}^S (\mathcal{L}_{k+1}(\mathbf{w}_s) - \mathcal{L}_k(\mathbf{w}_s))^2.$$

Теорема (Киселев, 2025)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация,  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$  и для всех  $i = 1, \dots, k+1$  верно  $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$ , тогда

$$\Delta_2(k+1) \leq \frac{12M_{\ell}^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}}{(k+1)^2} = \mathcal{O}(k^{-2}).$$





## Среднеквадратичный критерий сходимости в подпространстве наибольшей кривизны размерности $D$

Обозначим  $\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$ ,  $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$ ,  $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D] \in \mathbb{R}^{N \times D}$ ,  $\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$ , тогда среднеквадратичный критерий с  $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$ :


$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[ (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

На практике вычисляется методом Монте—Карло через  $\mathbf{w}_s = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}_s$ , где  $\mathbf{z}_s \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$ .

Теорема (Киселев, 2026)

Пусть в  $\mathcal{U}_R(\mathbf{w}_k^*)$  справедлива квадратичная аппроксимация,  $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_g$  и для всех  $i = 1, \dots, k+1$  верно  $|\ell_i(\mathbf{w}_k^*)| \leq M_\ell$ ,  $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_H$ , тогда




$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_g^2 + 3\sigma^4 (D^2 + 2D)M_H}{(k+1)^2} = \mathcal{O}(k^{-2}).$$



## Вычислительный эксперимент 2

- 1) 10-классовая классификация на MNIST;
- 2) Архитектура MLP, варьируются  $L$  и  $h$ ;
- 3) Численные значения критериев вычисляются методом Монте—Карло со 100 точками;
- 4) Собственные значения и векторы матрицы Гессе вычисляются методом степенной итерации.

| Критерий            | Оценка $\alpha$ | $R^2$ | Теория |
|---------------------|-----------------|-------|--------|
| $\Delta_1$          | 2,33            | 0,63  | 1      |
| $\Delta_2$          | 1,94            | 1,00  | 2      |
| $\Delta_2^{(D=5)}$  | 1,80            | 0,96  | 2      |
| $\Delta_2^{(D=10)}$ | 1,83            | 0,99  | 2      |
| $\Delta_2^{(D=20)}$ | 1,84            | 0,99  | 2      |



# Достаточный размер выборки и законы масштабирования

## Достаточный размер выборки

$$\Delta(m) \in \left\{ \Delta_1(m), \Delta_2(m), \Delta_2^{(D)}(m) \right\}$$

$$\forall m \geq m^* \quad \Delta(m) \leq \varepsilon$$

## Архитектурно-зависимая локальная кривизна

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2$$

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R$$

## Ключевой вывод

Архитектура модели влияет на достаточный размер выборки через **локальную кривизну** и скорость **стабилизации ландшафта** функции потерь.

## Теоретическая схема законов масштабирования

$$\mathcal{L}_m(\mathbf{w}_m^*) \lesssim E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}$$

## Следствия

- 1) Рост  $N$  уменьшает ошибку выразимости  $\Phi(N)$ ;
- 2) Рост  $m$  уменьшает вклад конечности выборки как  $m^{-\rho}$ ;
- 3) Коэффициент при  $m^{-\rho}$  определяется архитектурой через  $M_{\mathbf{G}}(\mathcal{A})$ .

# Стабилизация правдоподобия линейной регрессии в точке ОМП

## Вероятностная линейная регрессия

$$\mathbf{x} \in \mathbb{R}^n, \quad \mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}$$

$$y \in \mathbb{R}, \quad \mathbf{y}_m = [y_1, \dots, y_m]^\top \in \mathbb{R}^m$$

$$L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m | \mathbf{X}_m, \mathbf{w}) = \prod_{i=1}^m \mathcal{N}(y_i | \mathbf{w}^\top \mathbf{x}_i, \sigma^2)$$


$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w} \in \mathbb{R}^n} L(\mathfrak{D}_k, \mathbf{w}), \quad \mathbb{E} \hat{\mathbf{w}}_k = \mathbf{m}_k, \quad \mathbb{D} \hat{\mathbf{w}}_k = \Sigma_k$$

$M$ -достаточный размер:  $\forall k \geq m^*$

$$M(k+1) = |\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon$$

Теорема (Киселев, 2024)

Пусть  $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$  и  $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$  при  $k \rightarrow \infty$ , тогда определение  $M$ -достаточности корректно, то есть  $\forall \varepsilon > 0 \exists m^* \in \mathbb{N} : \forall k \geq m^* M(k) \leq \varepsilon$ .



$D$ -достаточный размер:  $\forall k \geq m^*$

$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon$$


# Апостериорные распределения линейной регрессии на подвыборках

Апостериоры на схожих подвыборках  $|\mathfrak{D}_k \triangle \mathfrak{D}_{k+1}| = 1$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \Sigma_0), \quad p_k(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_k) = \mathcal{N}(\mathbf{w} | \mathbf{m}_k, \Sigma_k)$$

$$\Sigma_k^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{X}_k, \quad \mathbf{m}_k = \Sigma_k \left( \Sigma_0^{-1} \mathbf{m}_0 + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{y}_k \right)$$

$$D_{\text{KL}}(p \| q) = \int p(\mathbf{w}) \log \frac{p(\mathbf{w})}{q(\mathbf{w})} d\mathbf{w}, \quad \text{s-score}(p, q) = \frac{\int p(\mathbf{w}) q(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int p(\mathbf{w} - \mathbf{b}) q(\mathbf{w}) d\mathbf{w}},$$



*KL*-достаточный размер:  $\forall k \geq m^*$

*S*-достаточный размер:  $\forall k \geq m^*$

$$KL(k+1) = D_{\text{KL}}(p_k \| p_{k+1}) \leq \varepsilon$$


$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \leq \varepsilon$$

Теорема (Киселев, 2024)

Пусть для всех  $i = 1, \dots, k+1$  верно  $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$ ,  $|y_i| \leq M_y$  и  $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$  при  $k \rightarrow \infty$ , тогда определения *KL*- и *S*-достаточности корректны, а для разбиения выборки  $\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}}$  верно  $D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0$ .

## Вычислительный эксперимент 3

- 1) Рассматриваются задачи регрессии и классификации на синтетических и реальных данных из библиотеки UCI;
- 2) Варьируется значение гиперпараметра  $\varepsilon$  для исследования зависимости критериев  $M$ -,  $D$ -,  $KL$ - и  $S$ -достаточности от него;



По графикам видно, что  $M$ - и  $S$ -достаточные размеры выборки более консервативны по сравнению с их аналогами  $D$ - и  $KL$ -достаточности, соответственно.

## Выносятся на защиту

- 1) Теоремы о верхних оценках спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
- 2) Критерии стабилизации ландшафта функции потерь в нейронных сетях, построенные для одной точки, для распределения точек в полном пространстве параметров и для подпространства главных собственных направлений матрицы Гессе.
- 3) Теоретическая схема законов масштабирования параметрических моделей машинного обучения, связывающая архитектуру модели, локальную кривизну оптимизационной поверхности и объем обучающей выборки.
- 4) Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь.
- 5) Критерии достаточного размера выборки для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров при увеличении объема данных.

# Список работ автора по теме диссертации

## Публикации в рецензируемых научных журналах (BAK, Web of Science, Scopus)

- 1) **Kiselev N.**, Meshkov V., Grabovoy A. Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2025.
- 2) Meshkov V., **Kiselev N.**, Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *Ivannikov ISPRAS Open Conference*, 2024.
- 3) **Kiselev N.**, Grabovoy A. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.
- 4) **Kiselev N.**, Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 5) **Kiselev N.**, Grabovoy A. Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.

## Выступления с докладом

- 1) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // Открытая конференция ИСП РАН, 2025.
- 2) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // 22-я Всероссийская конференция с международным участием «Математические методы распознавания образов», 2025.
- 3) Сходимость поверхности функции потерь как признак достаточного размера выборки // 67-я Всероссийская научная конференция МФТИ, 2025.
- 4) Определение достаточного размера выборки по апостериорному распределению параметров модели // 66-я Всероссийская научная конференция МФТИ, 2024.